



INSTITUTO TECNOLÓGICO Y DE ESTUDIOS
SUPERIORES DE MONTERREY

***Conformación de equipos y planteamiento del
proyecto***

Mayoral Terán Alexandro

Matrícula: A01795899

Sarmiento Cervantes Jacqueline

Matrícula: A01795863

Diseño de componentes para requerimientos de información financiera basado en técnicas de procesamiento de lenguaje natural (NLP)

1. Antecedentes

De acuerdo con el artículo 2do de la Ley del Banco de México, éste tiene como finalidad proveer a la economía del país de moneda nacional. En la consecución de esta finalidad tendrá como objetivo prioritario procurar la estabilidad del poder adquisitivo de dicha moneda. Otras finalidades del Banco son promover el sano desarrollo del sistema financiero y propiciar el buen funcionamiento de los sistemas de pagos.

Conforme a los objetivos anteriores, al interior del Banco, la Dirección General de Estabilidad Financiera (DGEF) realiza funciones que se apegan a procurar la estabilidad financiera y promover el sano desarrollo del sistema financiero. Adscrita a dicha dirección, se encuentra la Dirección de Información del Sistema Financiero (DISF) que se encarga de recabar, generar y analizar información de las instituciones financieras con objeto de coadyuvar a cumplir al Banco con sus finalidades.

Para recopilar la información de las instituciones financieras, se requieren mecanismos estructurados con el fin de monitorear sus operaciones y riesgos.

Estos mecanismos se materializan a través de requerimientos de información, los cuales deben diseñarse con base en marcos regulatorios como la Ley de Instituciones de Crédito, la Circular Única de Bancos, disposiciones y circulares, así como en estándares internacionales y lineamientos internos.

El proceso de diseño implica traducir disposiciones normativas en estructuras de datos denominadas formularios, catálogos asociados, validaciones técnicas y de negocio, y documentación detallada de apoyo para las instituciones. Actualmente, este proceso es intensivo en conocimiento, altamente manual y puede presentar inconsistencias entre equipos.

En este contexto, surge la necesidad de explorar herramientas basadas en inteligencia artificial que permitan apoyar con el análisis de documentos regulatorios y facilitar la estructuración de requerimientos de información. El presente proyecto propone el desarrollo de un modelo basado en técnicas de procesamiento de lenguaje natural que asista al personal de la DISF en el diseño y mejora de requerimientos de información, promoviendo eficiencia, consistencia y estandarización.

Cabe señalar que el alcance de este proyecto únicamente corresponde al desarrollo y optimización del modelo con una utilidad simple, debido al corto intervalo de tiempo con el que se cuenta para implementarlo, sin embargo, se espera que en el futuro el modelo se desarrolle en un ambiente productivo, con múltiples funcionalidades y que sea integrado en un software para utilización de los usuarios finales.

2. Entendimiento del negocio

2.1 Formulación del problema

El proceso de diseño de requerimientos de información financiera implica analizar y entender grandes volúmenes de documentación regulatoria y traducir las necesidades desprendidas de dichos textos en estructuras de datos y demás componentes consistentes con la supervisión que se requiere realizar y que cumpla con los objetivos definidos por Banco de México. Este proceso consiste en diseñar, de manera creativa, los siguientes elementos:

- **Formulario:** Estructura de datos en formato tabular que puede componerse de una o varias tablas a las que denominamos “secciones”. Dichas tablas contienen tantos campos como el diseñador requiera, siempre buscando optimizar el proceso de acopio de información. El nombre de los campos y el tipo de dato asociado a cada uno se definen en esta etapa.
- **Catálogos:** Tablas que contienen valores asociados a los campos de las secciones del formulario. Por ejemplo, catálogo de claves de conceptos permitidos en un campo, catálogo de monedas, catálogo de instituciones, etc.
- **Validaciones técnicas:** Reglas que se definen a partir de los campos diseñados y que corresponden a aquellas de forma o formato que deben cumplir los mismos. Por ejemplo, que el formato del campo fecha sea “aaaa-mm-dd”, que la información en un campo numérico sea numérica, etc.
- **Validaciones de negocio:** Similares a las validaciones técnicas, aunque estas reglas buscan la consistencia entre campos de acuerdo con el sentido lógico, financiero o de negocio. Adicionalmente también validan la consistencia entre el cruce de secciones. Por ejemplo, si a través de un formulario contable se recaba una sección de activos desagregados, una de pasivos y una de capital, una validación de negocio verificaría que la suma de los activos sea igual a la suma de pasivos más capital.
- **Ayudas genéricas:** Documento que describe el motivo, objetivo, frecuencia de transmisión y funcionamiento del formulario de manera detallada. Incluye la estructura de campos, catálogos y validaciones y se comparte a las instituciones como apoyo para el entendimiento del mismo.

Los formularios son transmitidos a través de un sistema denominado SAIFWeb, propiedad de la DISF. El equipo de TI es el responsable de integrar las validaciones diseñadas por el equipo de negocio en dicho sistema para que se detonen cuando se encuentren inconsistencias en la información y no permita que se integren a las bases de datos del Banco.

Actualmente el proceso de diseño de los formularios:

- requiere un alto nivel de especialización,
- es intensivo en tiempo,
- y puede presentar variabilidad en los resultados.

2.2 Contexto

La DISF realiza diversas labores adicionales al diseño de formularios y sus elementos asociados; por ello, se requiere agilizar la manera en la que se lleva a cabo este proceso, pero sin descuidar el detalle con el que se realiza.

El diseño de los formularios depende en su totalidad del entendimiento de la regulación y el conocimiento financiero del equipo que los elabora. En general, el personal encargado de esta labor tiene un profundo conocimiento del negocio más no de bases de datos y, por ende, los formularios no siempre son diseñados de la manera más óptima.

Sin embargo, la información acopiada por la DISF es fundamental para la supervisión que realiza Banco de México, por lo que la correcta definición de estos requerimientos es de gran importancia para garantizar la calidad de la misma, facilitar su validación y análisis.

Una mejora en este proceso permitiría incrementar la eficiencia operativa y la estandarización.

2.3 Objetivos

El objetivo del presente proyecto consiste en desarrollar un modelo basado en técnicas de Procesamiento de Lenguaje Natural que permita identificar y estructurar componentes relevantes para el diseño de requerimientos de información a partir de documentos regulatorios.

El proyecto se implementará mediante notebooks que permitirán simular el comportamiento de un sistema donde el usuario:

- proporciona documentos regulatorios.
- incluye instrucciones adicionales de manera opcional.
- ejecuta el procesamiento.

El MVP se validará inicialmente en notebooks, con el objetivo de transicionar a una interfaz interactiva y ligera que facilite su uso por parte del personal de la DISF.

Se requiere que, al observar documentos regulatorios y recibir una instrucción precisa, se generen archivos sugeridos correspondientes a:

- La estructura de la tabla o tablas del formulario.
- Catálogos asociados.

El alcance de este proyecto no contempla la generación de las validaciones técnicas, de negocio ni de las ayudas genéricas debido a que se trata de una primera aproximación técnica hacia el desarrollo de una herramienta más completa, además del corto tiempo con el que se cuenta para el desarrollo, sin embargo, en un futuro también se considerará incluir estas funcionalidades.

2.4 Preguntas clave

- ¿Cómo identificar información relevante en documentos regulatorios extensos?
- ¿Cómo dar tratamiento a tablas que se encuentran en dichos documentos?
- ¿Qué métodos permiten recuperar información útil de manera más eficiente?
- ¿Cómo elaborar un formulario que optimice el acopio de información?
- ¿Qué tan consistentes son las estructuras generadas?
- ¿Cómo comparar diferentes enfoques de procesamiento de texto?

2.5 Involucrados

Las personas involucradas de manera activa en el diseño de formularios y sus componentes son los analistas de información y jefes de oficina. Los subgerentes y el gerente se encargan de dar sugerencias, supervisar y aprobar los documentos elaborados. Todos los involucrados son personal de la DISF.

3. Entendimiento de los datos

3.1 Descripción de los datos

El proyecto utilizará un conjunto de datos compuesto por:

- Documentos regulatorios en formato PDF como extractos de la Ley de Instituciones de crédito, Circular Única de Bancos, Circular 3/2012, Disposiciones de Liquidez, documentos emitidos por el Comité de Basilea, entre otros.
- Ejemplos de requerimientos de información:
 - formularios
 - catálogos

Estos documentos serán transformados en unidades de análisis mediante técnicas de segmentación de texto.

3.2 Técnica de *Machine Learning*

El problema se aborda como:

- Procesamiento de Lenguaje Natural (NLP).
- Recuperación de información.
- Enfoque no supervisado, basado en similitud semántica.
- Generación Estructurada de Datos (Structured Data Generation)

3.3 Variables

Las variables de entrada para la fase de entrenamiento incluyen:

- Documentos regulatorios.

- Formularios y catálogos asociados.
- Texto de consulta o instrucciones.

Mientras que cuando el proceso sea utilizado por el usuario esperará recibir como entrada:

- Documentos regulatorios.
- Instrucciones en un texto (opcional).

Las variables de salida corresponderán con tablas correspondientes a:

- Formulario.
- Catálogos asociados.

El usuario esperará ver dichas tablas dentro de una carpeta seleccionada en formato .xlsx

4. Cronograma de trabajo

El proyecto no corresponde con un modelo supervisado tradicional, sin embargo, se buscará que se apegue en su mayoría con el cronograma esperado en la plataforma. A continuación, se señalan los entregables esperados.

Avance	Actividad	Fecha de entrega
1	Análisis exploratorio de documentos	10/05/2026
2	Preparación de datos y representaciones	17/05/2026
3	Implementación de modelo <i>baseline</i>	24/05/2026
4	Modelos alternativos y comparación	31/05/2026
5	Modelo final	07/06/2026

Tabla 1. Cronograma de trabajo

Referencias

- Banco de México. (1993, diciembre 23). *Ley del Banco de México*. <https://www.banxico.org.mx/marco-normativo/marco-juridico/ley-del-banco-de-mexico/%7B65E243F0-4E89-DE55-74AC-7AA890B13379%7D.pdf>
- Banco de México. (2025, noviembre 19). *Reglamento Interior del Banco de México*. <https://www.banxico.org.mx/marco-normativo/marco-juridico/ley-del-banco-de-mexico/%7B65E243F0-4E89-DE55-74AC-7AA890B13379%7D.pdf>
- Jurafsky, D., & Martin, J. H. (2023). *Speech and language processing* (3rd ed., draft). <https://web.stanford.edu/~jurafsky/slp3/>
- Manning, C. D., Raghavan, P., & Schütze, H. (2008). *Introduction to information retrieval*. Cambridge University Press. <https://nlp.stanford.edu/IR-book/>
- Reimers, N., & Gurevych, I. (2019). Sentence-BERT: Sentence embeddings using Siamese BERT-networks. *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing (EMNLP)*. <https://doi.org/10.18653/v1/D19-1410>
- Lewis, P., Perez, E., Piktus, A., Petroni, F., Karpukhin, V., Goyal, N., Küttler, H., Lewis, M., Yih, W.-t., Rocktäschel, T., Riedel, S., & Kiela, D. (2020). Retrieval-augmented generation for knowledge-intensive NLP tasks. *Advances in Neural Information Processing Systems*, 33. <https://arxiv.org/abs/2005.11401>