

Avance 4 · Modelos Alternativos

Rúbrica modificada para el ciclo T2026 Spring · team-facing

22 May 2026 · Asesor: **Dr. Horacio Martínez Alfaro** · hma@tec.mx

1. Introducción

Como parte de la preparación del **Avance 4 (Modelos Alternativos)**, he revisado la rúbrica oficial del Tec y la versión adaptada para proyectos con componente LLM / Gen AI. Encontré huecos recurrentes que aparecieron en Avances anteriores y que conviene cerrar antes de la fase de comparación de modelos. Esta versión modificada será aplicada en E4.

CÓMO LEER ESTE DOCUMENTO

La rúbrica oficial (Q / A) cubre proyectos tabulares y supervisados clásicos. La rúbrica adaptada LLM / Gen AI (MA) se aplica a proyectos con componente NLP, RAG, fine-tuning, agentes o ML generativo (materiales). Si el proyecto es híbrido tabular+textual (60), se usan ambas con la ponderación documentada por equipo en el asesor.

2. Dimensiones nuevas

Tres dimensiones nuevas, espejadas en ambas variantes (oficial y LLM). Cierran el ciclo entre la viabilidad declarada en E3 y la selección en E4.

A5 / MA5 — Significancia estadística de la comparación

QUÉ SE PIDE EN E4

Comparar 6 modelos con métricas puntuales ("Modelo A: 0.74, Modelo B: 0.72") sin tests es teatro.

- **Intervalos de confianza por bootstrap** (≥ 1000 resamples) sobre la métrica primaria, por modelo.
- **Tests pareados de significancia:** McNemar (clasificación), paired-t (continuas), bootstrap pareado (ranking @k).
- **Empate estadístico:** modelos con CIs solapados se reportan como tied — la elección se hace por costo / latencia / interpretabilidad.
- Variante LLM (MA5): varianza entre runs con **temperature** > 0 ; LLM-as-judge requiere kappa de Cohen entre jueces.

A6 / MA6 — Análisis de errores por modelo + desagregación por subgrupo

QUÉ SE PIDE EN E4

Continuación natural del Q8 / BL8 de E3: ejecutar el análisis de errores en **cada uno** de los 6 candidatos, no solo en el baseline.

- Modelos con misma métrica agregada pueden esconder patrones de error muy distintos.
- **Desagregación por subgrupo obligatoria** — por familia clínica, entidad legal / categoría, región / RFM, composición química, longitud / idioma de query (60), etc.
- Reportar: ¿hay subgrupos donde el modelo "ganador" rinde peor que el "segundo lugar"?

- Variante LLM (MA6): separar errores por etapa — retrieval falló / generación alucinó / formato inadecuado.

A7 / MA7 — Perfil de interpretabilidad y costo computacional

QUÉ SE PIDE EN E4

Los 6 modelos pintan una frontera multidimensional, no solo calidad. Reportar por candidato: tiempo de entrenamiento, footprint de memoria, latencia P50 / P95, tamaño del artefacto, **perfil de interpretabilidad** (nativa / vía SHAP / opaca).

- Filtro de stakeholders: para proyectos con stakeholders que exigen explicabilidad (BMW, Banxico, Corona, Taolab, ACCIONA), marcar cuáles candidatos satisfacen el requisito.
- Atención: la atención NO es explicación causal.
- Variante LLM (MA7): añade costo por consulta (tokens × precio), vendor lock-in spectrum (self-hostable / multi-cloud / cloud-único), residencia de datos (Banxico, Corona Colombia).

3. Dimensiones modificadas

Cuatro dimensiones de la rúbrica oficial fueron refinadas (no son nuevas, pero el criterio de evaluación se endureció). Las dimensiones LLM equivalentes recibieron refinamientos paralelos.

Variante oficial — A1 a A4

Dim	Tema	Cambio
A1	Construir 6 modelos diferentes	Los 6 deben justificarse por diversidad de inductive biases (lineal, tree-based, kernel, neural, probabilístico, domain-specific). Párrafo de justificación obligatorio.
A2	Comparar el rendimiento	Marco riguroso: eval set congelado desde E3 , métrica primaria reutilizada, ≥3 métricas reportadas, Pareto frontier plot , tabla comparativa, reproducibilidad heredada de E3-Q7.
A3	Ajuste de hiperparámetros	Tuning controlado sobre los 6 candidatos con mismo presupuesto computacional (grid uniforme o tiempo límite parejo). CV interna para evitar tuning sobre el eval set.
A4	Top-2 + ajuste profundo + elección final	El modelo final debe superar el umbral E3-BL5 por margen estadísticamente significativo. Si ninguno lo supera, pivotar explícitamente (revisar planteamiento, solicitar datos, aceptar baseline E3).

Variante LLM / Gen AI — MA1 a MA4

Dim	Tema	Cambio
MA1	6 configuraciones LLM	Al menos UNA candidata debe ser self-hostable (Llama, Mistral, Gemma en vLLM / TGI / Ollama). Razón: data residency + independencia de vendor lock-in.
MA2	Comparación multi-dimensional	Igual que A2 + verificación de contaminación por candidato (test “no-context” de BL3 por cada LLM, pues los corpora de pre-entrenamiento difieren).
MA3	Hiperparámetros LLM	Decoding / RAG / prompt / fine-tuning, igual que la versión anterior. Nuevo requisito: cada variante probada lleva un prompt versionado (hash, git ref, DSPy program ID).
MA4	Top-2 + ajuste sin leakage	DSPy / Promptfoo / LangSmith optimizan contra el eval set — reservar held-out separado (congelado desde E3) para el número final reportado. Más chequeo contra E3-BL5.

4. Síntesis

RESUMEN DE QUÉ CAMBIÓ

- **Dimensiones nuevas** (3 en cada variante): significancia estadística (A5 / MA5), análisis de errores por modelo + subgrupo (A6 / MA6), perfil de interpretabilidad + costo (A7 / MA7).
- **Dimensiones modificadas** (4 en cada variante): A1 / MA1 diversidad de inductive biases, A2 / MA2 marco riguroso de comparación + Pareto + contaminación (LLM), A3 / MA3 prompt versioning (LLM), A4 / MA4 chequeo final contra el umbral E3-BL5.
- Variante LLM añade: al menos un candidato self-hostable (MA1), vendor lock-in spectrum (MA7).

Fuente: Entrega 4 Rúbrica, Canvas PI. Si tu proyecto cae en la categoría LLM/Gen AI/generativo no-textual, considera la columna derecha (MA) en cada sección.