

Rúbrica E3 · Modelo Baseline (versión modificada · 2026-05-18)

Construir un modelo de referencia que permita evaluar la viabilidad del problema. Si el baseline tiene rendimiento similar al azar, el problema podría ser intrínsecamente difícil o los datos podrían no contener suficiente información. Facilita gestión de expectativas.

Fuente: Entrega 3 Rúbrica, Canvas PI.

Rúbrica oficial (tradicional)

8 dimensiones · 3 nuevas · 4 modificadas · 1 sin cambios

E3-Q1

MODIFICADA

Baselines: trivial + simple (con lift medible)

Reportar DOS baselines, no uno:

- (a) Trivial — predictor constante (clase más frecuente para clasificación; mediana/media para regresión; popularidad global para recomendación). Establece el piso absoluto.
- (b) Simple — modelo paramétrico básico (Regresión Logística / Lineal, Naive Bayes, Decision Stump, kNN). Es el "modelo baseline" que el sistema final debe superar.

Cualquier modelo más complejo debe reportarse junto a estos dos con el lift cuantificado.

Cambio: Antes: 'un algoritmo baseline'. Ahora: dos baselines con lift.

E3-Q2

MODIFICADA

Importancia de características (correlacional, no causal)

Identificar las features que más contribuyen al desempeño:

- Coeficientes (modelos lineales) o feature_importances_ (árboles).
- Permutation importance sobre validación (más robusto).
- SHAP local + global si el modelo lo permite.

REGLA: estas técnicas son CORRELACIONALES, no causales. Documentar la diferencia explícitamente — features con alta importancia pueden reflejar leakage o spurious correlation, no causa.

Cambio: Antes: 'determinar la importancia'. Ahora: + distinguir correlación de causalidad explícitamente.

E3-Q3

Sin cambios

Sub/sobreajuste del modelo en datos de entrenamiento

Reportar métrica en train vs validación. Diferencia $\gg 0$ indica overfitting; ambos bajos indica underfitting. Para modelos con capacidad ajustable, mostrar la curva de aprendizaje.

E3-Q4

MODIFICADA

Métrica primaria declarada a priori + 2-3 secundarias

Antes de modelar:

- Elegir UNA métrica primaria alineada con el KPI de negocio.
- Definir 2-3 métricas secundarias que cubran robustez, costo y

equidad.

- Justificar la elección: ¿por qué macro-F1 y no accuracy?

¿por qué MAE y no RMSE? Anclar la decisión en la asimetría de costos del error.

Reportar todas las métricas pero declarar el ganador por la primaria.

Crítico: Elegir la métrica DESPUÉS de ver los resultados es un anti-patrón frecuente. Declararla en el notebook ANTES del primer fit.

Cambio: Antes: 'la métrica adecuada'. Ahora: + declarada a priori, + ≥ 1 primaria + 2-3 secundarias.

E3-Q5

MODIFICADA

Desempeño mínimo = baseline trivial + Δ justificado por negocio

El piso no es un número absoluto ("85% accuracy"); es un LIFT sobre el baseline trivial de Q1(a):

- Δ pequeño (≤ 2 pts) $\rightarrow$ el modelo no aporta valor; revisar features o problema.
- Δ moderado (5-10 pts) $\rightarrow$ válido si el costo de implementación es bajo.
- Δ grande (> 10 pts) $\rightarrow$ fuerte señal de viabilidad.

El tamaño de Δ debe justificarse contra el valor de negocio (no contra otros papers o benchmarks externos).

Cambio: Antes: 'desempeño mínimo a obtener'. Ahora: + reformulado como lift sobre baseline.

E3-Q6

NUEVA

Política de split de datos y validación cruzada

Declarar explícitamente:

- Estrategia de split (random / estratificado / temporal).
- Ratios (típicamente 70/15/15 o 80/10/10).
- Random seed.
- Política específica del dominio:
- Tabular: estratificar por clase objetivo.
- Series temporales: split temporal estricto, NO shuffle.
- NLP: deduplicar antes del split; no permitir documentos

idénticos en train + val.

- RAG: split de queries, no de chunks.
- Materiales / generativo (Eq 53): hold-out de composiciones,

no de estructuras individuales.

- K-fold cross-validation como mínimo sobre el baseline simple;

reportar media $\pm$ desviación estándar.

- Análisis de drift entre splits (¿la distribución de la variable objetivo cambia significativamente entre train y test?).

Cambio: NUEVA. Esta dimensión no existía en la rúbrica original — pero sin ella todo lo demás es sospechoso.

E3-Q7

NUEVA

Reproducibilidad y artefactos

El baseline debe ser re-ejecutable:

- Random seeds fijos (numpy, sklearn, torch, framework-específico).
- Environment capturado (requirements.txt, lockfile, conda env).
- Pipeline guardado como artefacto (sklearn Pipeline + joblib,

o equivalente) que pueda cargarse en E4.

- Notebook se ejecuta end-to-end sin intervención manual.
- Hyperparámetros documentados en el notebook (no en código

ad-hoc en otra parte).

Cambio: NUEVA. Garantiza que E4 pueda partir del baseline sin rehacer trabajo.

E3-Q8

NUEVA

Análisis de errores

No basta con métricas agregadas: examinar los casos en que el modelo falla.

- Clasificación: matriz de confusión + ejemplos representativos de cada celda fuera de la diagonal. Categorizar errores (ambiguity, OOV, etiqueta ruidosa, confusión entre clases cercanas).
- Regresión: distribución de residuos, residuos vs features, casos con residuo extremo.
- Recomendación: queries con hit-rate 0, segmentos sin cobertura.
- Por subgrupo: desempeño desagregado (por categoría, región, franja temporal, idioma).

Producir 3-5 observaciones cualitativas que informen el diseño de E4 (modelos alternativos).

Cambio: NUEVA. Esta es la diferencia entre 'corrí el baseline' y 'entiendo qué pasó'.

Rúbrica adaptada LLM / Gen AI

8 dimensiones · 3 nuevas · 5 modificadas · 0 sin cambios

BL1

MODIFICADA

Baselines trivial + simple (LLM)

Mapea a: E3-Q1

Reportar DOS baselines:

- (a) Trivial: predictor constante por tipo de tarea.
- (b) Simple: el más barato razonable.

Baselines por tipo de proyecto:

Ejemplos por tipo de proyecto:

clasificacion nlp

Trivial: clase más frecuente. Simple: TF-IDF + LogReg / Naive Bayes. Avanzado debe superar a ambos.

rag qa

Trivial: LLM solo sin recuperación (responder con conocimiento paramétrico). Simple: BM25 sin reranker. RAG semántico debe superar a BM25 medido en Recall@k.

recomendador embeddings

Trivial: top-K más populares. Simple: recientes del usuario + popularidad híbrida.

generacion condicional

Trivial: prompt mínimo zero-shot. Simple: zero-shot + system prompt corto.

ml generativo imagen materiales

Trivial: muestreo aleatorio de train. Simple: modelo pre-entrenado sin fine-tuning.

Criterio: Si el pipeline RAG no supera al baseline BM25, el componente semántico no está aportando valor.

Cambio: Antes: 'baseline trivial pero honesto' (uno solo). Ahora: trivial + simple, ambos requeridos.

BL2

MODIFICADA

Importancia de características (correlacional, no causal — LLM)

Mapea a: E3-Q2

- Contribución del prompt: ablation prompting (quitar instrucciones, few-shot, secciones del system prompt).
- Contribución del retrieval: con/sin contexto, sensibilidad a k, longitud y orden de documentos.
- Contribución de chunks: qué chunks aparecen más en top-K.
- Attribution sobre texto: LIME/SHAP adaptados, atención (cuidado: atención NO es explicación causal).
- Para generativos no-textuales (Eq 53): sensibilidad a guidance_factor, md_steps, semilla.

Riesgo: Características irrelevantes en prompt/contexto degradan rendimiento, latencia y costo.

Cambio: Nota explícita sobre correlación vs causalidad añadida (espejo de Q2).

BL3

MODIFICADA

Sub/sobreajuste, memorización y contaminación de datos

Mapea a: E3-Q3

- Fine-tuning: perplexity train vs holdout, accuracy train vs val, out-of-domain.
- Few-shot / in-context learning: ¿está copiando los ejemplos? (held-out queries).

- RAG: ¿responde solo cuando el chunk relevante está en contexto?

¿qué pasa con queries multi-chunk?

- Memorización del modelo base: test "no-context" (¿el LLM ya conoce la respuesta sin recuperación?).
- ****DATA CONTAMINATION CHECK****: ¿el dataset estaba en el corpus de pre-entrenamiento del LLM? Para Banxico, QuickBooks, job listings de Kaggle — probable overlap parcial. Probar con queries paráfraseadas o sintéticas para detectar respuestas memorizadas.
- Generativo: diversidad (distinct-n, self-BLEU, IS/FID).

Cambio: AÑADIDO: data contamination check explícito.

BL4

MODIFICADA

Métrica primaria declarada a priori (1 primaria + 2-3 secundarias)

Mapea a: E3-Q4

Antes de modelar declarar UNA métrica primaria del menú:

- Recuperación (RAG): Recall@k, MRR, nDCG, hit-rate.
- Generación referenciada: BLEU, ROUGE, METEOR, BERTScore.
- Generación abierta: similitud semántica vs gold, LLM-as-judge

calibrado, evaluación humana.

- RAG end-to-end: faithfulness, answer relevancy, context precision/recall (RAGAS, TruLens).

- Generativo imagen: FID, IS, CLIP-score.
- Materiales (Eq 53): validity rate, novelty, energía promedio, cobertura composicional.

Más 2-3 secundarias que cubran:

- calidad operacional (hallucination rate, refusal rate)
- costo (latencia P50/P95, costo por consulta)
- robustez (variación entre runs con temperature > 0)

Crítico: BLEU alta puede convivir con respuestas inútiles. Elegir DESPUÉS de ver los resultados es un anti-patrón frecuente.

Cambio: Antes: menú completo de métricas. Ahora: UNA primaria declarada a priori + 2-3 secundarias.

BL5

MODIFICADA

Desempeño mínimo = lift sobre baseline trivial + SLOs operativos

Mapea a: E3-Q5

Definir el umbral en cuatro ejes:

- Lift sobre baseline trivial: superar BM25/popularidad/zero-shot por margen significativo (p. ej. +10 puntos en métrica primaria).
- Cumplimiento de SLOs operativos: latencia P95 < X ms, costo < Y per 1000 consultas, hallucination rate < Z%.
- Aceptabilidad humana: muestra de N respuestas, ≥M% útiles (con criterio escrito).
- ****Costo de revisión humana a escala****: ¿cuánto cuesta revisar las respuestas dudosas del sistema cuando opere en producción? Si el costo de revisión > ahorro generado, el sistema no es viable.
- Validación de negocio: % conversión, reducción de tiempo del agente humano, ahorro estimado.

Cambio: AÑADIDO: eje de costo de revisión humana a escala.

BL6

NUEVA

Política de split y validación (LLM)

Mapea a: E3-Q6

- RAG: split de ****queries**** (no de documentos). El corpus es compartido entre train/val/test; lo que se separa son las consultas evaluadas.
- Fine-tuning: deduplicación estricta antes del split; verificar que no haya overlap por hash o n-gram entre train y val.
- Few-shot / in-context: held-out queries que NO se parezcan a los ejemplos del prompt (variación léxica, paráfrasis).
- Generativo (Eq 53): hold-out de composiciones químicas completas, no de estructuras individuales dentro de una composición.
- Eval set fijo y compartido: ≥100 queries representativas del caso de uso, congelado desde E3 y reutilizado en E4-E5.

Cambio: NUEVA. Espejo LLM de Q6 — el eval set fijo es crítico para LLM por costo.

BL7**NUEVA**

Reproducibilidad LLM (seed, temperature, prompt versioning)

Mapea a: E3-Q7

- temperature=0 (o seed fija si la API lo soporta) para que comparaciones sean estables.
- Versionado de prompts: el system prompt y few-shot examples son artefactos. Guardar en archivo con hash o versión.
- Snapshot del modelo: registrar versión exacta (gpt-4o-2024-08-06, claude-sonnet-4-5, etc.) — los modelos hosted cambian sin aviso.
- Logs estructurados de cada call: prompt, response, latencia, tokens. Necesario para auditar y rehacer la evaluación.
- Cache de embeddings: indexar una sola vez, reutilizar.

Cambio: NUEVA. Espejo LLM de Q7 — adicional: prompts versionados.

BL8**NUEVA**

Análisis de errores LLM (retrieval, hallucination, validity)

Mapea a: E3-Q8

Examinar los casos en que el sistema falla:

- RAG: separar errores por etapa:
- retrieval falló (chunk relevante no en top-K)
- retrieval correcto pero generación alucinó
- generación correcta pero formato inadecuado.
- Clasificación con LLM: matriz de confusión sobre eval set,

con ejemplos textuales por celda.

- Generación abierta: muestra de 20-30 respuestas + clasificación manual (útil / parcial / incorrecta / alucinación / refusal).
- Generativo (Eq 53): scatter de estructuras válidas vs inválidas sobre features; identificar regiones del espacio donde el modelo falla.
- Por subgrupo: desempeño desagregado (por tipo de query, longitud, idioma, dominio temático).

Producir 3-5 observaciones cualitativas que informen E4.

Cambio: NUEVA. Espejo LLM de Q8 — taxonomía de errores específica de LLM.

