

Avance 5 · Ensamblas, tabla comparativa y gráficos

Rúbrica modificada para el ciclo T2026 Spring · team-facing

25 May 2026 · Asesor: [Dr. Horacio Martínez Alfaro](#) · hma@tec.mx

1. Introducción

Como parte de la preparación del **Avance 5 (Ensamblas, tabla comparativa y gráficos)**, he revisado la rúbrica oficial del Tec y la versión adaptada para proyectos con componente LLM / Gen AI. La rúbrica original cubre las tres acciones clave (construir ensambles, tabla comparativa, gráficos interpretativos) pero queda corta en tres aspectos que deciden si el modelo final realmente aporta valor sobre el mejor individual de E4.

CÓMO LEER ESTE DOCUMENTO

La rúbrica oficial (E5-A/B/C) cubre proyectos tabulares y supervisados clásicos. La rúbrica adaptada LLM / Gen AI (ENS-A/B/C/D/E/F) se aplica a proyectos con componente NLP, RAG, fine-tuning, agentes o ML generativo. Si el proyecto es híbrido tabular+textual (60), se usan ambas con la ponderación documentada por equipo con el asesor.

2. Ponderaciones por dimensión

Variante oficial

RESUMEN DE DIMENSIONES

Dim	Tema	Peso	Estado
E5-A	Construir modelos de ensamble (homogéneos + heterogéneos)	12	MODIFICADA
E5-B	Tabla comparativa ordenada por métrica primaria	18	MODIFICADA
E5-C	Gráficos significativos + frontera de Pareto	15	MODIFICADA
E5-D	Diversidad cuantificada de los base learners	15	NUEVA
E5-E	Calibración de salidas probabilísticas	15	NUEVA
E5-F	Lift estadísticamente significativo + cumplimiento de criterios stakeholder	25	NUEVA
Total		100	

Variante LLM / Gen AI

RESUMEN DE DIMENSIONES

Dim	Tema	Peso	Estado
ENS-A	Estrategias de ensamble homogéneas y heterogéneas (LLM)	12	MODIFICADA
ENS-B	Tabla resumen con métricas + tiempos + costos + thresholds	18	MODIFICADA
ENS-C	Visualizaciones interpretativas + Pareto frontier	15	MODIFICADA
ENS-D	Diversidad cuantificada de los base LLMs	15	NUEVA
ENS-E	Calibración de confidence + consistencia de salidas	15	NUEVA
ENS-F	Lift estadísticamente significativo + criterios stakeholder + costo justificado	25	NUEVA
Total		100	

3. Dimensiones nuevas

Tres dimensiones nuevas, espejadas en ambas variantes (oficial y LLM). Cierran el ciclo entre la diversidad declarada en E4-A1 y la decisión final del modelo de E5.

E5-D / ENS-D — Diversidad cuantificada de los base learners

QUÉ SE PIDE EN E5

Para que un ensemble sume valor, los base learners deben **discrepar en sus errores** — no solo en sus arquitecturas.

- **Disagreement rate** pareado: % de predicciones donde dos base learners discrepan.
- **Correlation of errors**: matriz de correlación de errores entre pares. Si >0.8 , el ensemble no aportará lift.
- **Oracle vs majority vote gap**: cuánto se está dejando en la mesa (oracle = acertar siempre que alguno acertó).
- Variante LLM (ENS-D): agreement matrix entre base LLMs, self-consistency rate (**temperature** >0), inter-judge kappa de Cohen, retriever diversity (RAG).

E5-E / ENS-E — Calibración de salidas probabilísticas

QUÉ SE PIDE EN E5

Los ensembles suelen producir probabilidades miscalibradas. Si el modelo se usa para tomar decisiones con umbral, la calibración importa más que la accuracy.

- **Brier score** y **ECE** (Expected Calibration Error) para el ensemble final y para cada base learner.
- **Reliability diagram**: confianza predicha (X) vs accuracy empírica (Y); ideal = diagonal.
- Si miscalibrado: aplicar Platt scaling o isotonic regression y reportar mejora.
- Variante LLM (ENS-E): además del confidence ECE, reportar consistencia entre runs (**temperature** >0), paraphrase invariance, y kappa entre 2+ jueces (idealmente humano + LLM).

E5-F / ENS-F — Lift estadísticamente significativo + criterios stakeholder

QUÉ SE PIDE EN E5

Pivote del avance. El modelo final debe satisfacer simultáneamente cuatro criterios:

- **(a) Lift estadísticamente significativo** sobre el mejor individual de E4 (paired test + bootstrap CI ≥ 1000 resamples). Si NO se observa, decisión válida es “el ensemble no aporta — se usa el mejor individual”. Documentar.
- **(b) Cumplimiento del umbral E3-BL5** con margen.
- **(c) Cumplimiento de los criterios stakeholder declarados en E0**: latencia, interpretabilidad, residencia de datos, costo operativo.
- **(d) Costo marginal justificado**: a volumen real, ¿cuánto más cuesta el ensemble vs el mejor individual? ¿el lift en métrica lo justifica?

4. Dimensiones modificadas

Tres dimensiones de la r brica oficial fueron refinadas. La variante LLM recibe los mismos refinamientos paralelos, con  nfasis en costo, latencia y hallucination rate como columnas first-class de la tabla.

Variante oficial — E5-A, E5-B, E5-C

Dim	Tema	Cambio
E5-A	Construir ensambles homog�neos + heterog�neos	Antes: "construir ensambles". Ahora: al menos UNA estrategia homog�nea (bagging, boosting) + UNA heterog�nea (stacking/blending sobre los 2-3 mejores individuales de E4, heredando la diversidad de A1).
E5-B	Tabla comparativa con thresholds expl�citos	Antes: tabla ordenada por m�trica. Ahora: incluye umbral E3-BL5 y mejor individual de E4 como referencias horizontales; la elecci�n final se defiende contra TODA la tabla, no solo el top-2. No es v�lido elegir el de mayor accuracy si el segundo est� estad�sticamente empatado y cuesta 10� menos.
E5-C	Frontera de Pareto + interpretaci�n por gr�fico	Antes: "gr�ficos significativos". Ahora: frontera de Pareto obligatoria (X: costo/latencia, Y: m�trica primaria) con TODOS los candidatos. El modelo final debe estar en la frontera o ser justificado por restricci�n de stakeholder. Cada gr�fico acompa�ado de UN p�rrafo de interpretaci�n.

Variante LLM / Gen AI — ENS-A, ENS-B, ENS-C

Dim	Tema	Cambio
ENS-A	Estrategias de ensamble LLM (homog�neas + heterog�neas)	Igual que E5-A para LLM: homog�neas (self-consistency, voting, multi-retrieval) + heterog�neas (cascading, MoE router, multi-agent debate, RRF, LLM-as-judge ensemble, stacking sobre logits/embeddings) ancladas en los 2-3 mejores de E4 (MA1).
ENS-B	Tabla con costo + latencia + hallucination rate + thresholds	Igual que E5-B + columnas costo/consulta (USD/1000 calls), latencia P50/P95, hallucination rate, tier del servicio. Referencias horizontales obligatorias: umbral E3-BL5 y mejor LLM individual de E4 (MA4).
ENS-C	Pareto frontier LLM + interpretaci�n	Igual que E5-C + visualizaciones espec�ficas LLM (matriz confusi�n, recall@k, faithfulness vs answer_relevancy, UMAP de embeddings, agent trajectory plots, materiales scatter energy vs natoms para).

5. S ntesis

RESUMEN DE QU  CAMBI 

- **Dimensiones nuevas** (3 en cada variante): diversidad cuantificada de base learners (D), calibraci n de salidas probabil sticas (E), lift estad sticamente significativo + criterios stakeholder (F).
- **Dimensiones modificadas** (3 en cada variante): A homog neas + heterog neas sobre los mejores de E4, B con umbral E3-BL5 + mejor individual como referencias horizontales, C con frontera de Pareto obligatoria.
- Variante LLM a ade: costo por consulta + latencia P50/P95 + hallucination rate como columnas first-class (ENS-B), Pareto frontier costo m trica como gr fico central (ENS-C).

IDEA CLAVE

“El ensemble no aporta” **es una decisión válida**. Si después de construir y comparar no se observa lift estadísticamente significativo sobre el mejor individual de E4, lo correcto es documentar esa decisión y usar el mejor individual — no forzar un ensemble por compromiso.

Fuente: Entrega 5 Rúbrica, Canvas PI. Si tu proyecto cae en la categoría LLM/Gen AI/generativo no-textual, considera la columna derecha (ENS) en cada sección.