

Avance 6 · Viabilidad e implementación en la nube

Rúbrica modificada para el ciclo T2026 Spring · team-facing

25 May 2026 · Asesor: [Dr. Horacio Martínez Alfaro](#) · hma@tec.mx

1. Introducción

Como parte de la preparación del **Avance 6 (Viabilidad e implementación en la nube)**, he revisado la rúbrica oficial del Tec y la versión adaptada para proyectos con componente LLM / Gen AI. La rúbrica original cubre dos preguntas amplias (¿es viable? ¿qué plataforma?) pero deja sin pedir aspectos que deciden si el sistema realmente vive en producción: SLO, monitoreo, compliance y handoff. Esta versión modificada se aplicará en E6.

CÓMO LEER ESTE DOCUMENTO

La rúbrica oficial (E6-A..E) cubre proyectos tabulares y supervisados clásicos. La rúbrica adaptada LLM / Gen AI (DEP-A..E) se aplica a proyectos con componente NLP, RAG, fine-tuning, agentes o ML generativo. Si el proyecto es híbrido tabular+textual (60), se usan ambas con la ponderación documentada por equipo con el asesor.

2. Ponderaciones por dimensión

Variante oficial

RESUMEN DE DIMENSIONES

Dim	Tema	Peso	Estado
E6-A	Decisión go/no-go condicional + recomendaciones accionables	25	MODIFICADA
E6-B	Plataforma cloud justificada con TCO + lock-in + residencia	20	MODIFICADA
E6-C	SLO + plan de monitoreo en producción	20	NUEVA
E6-D	Seguridad, compliance y manejo de PII	20	NUEVA
E6-E	Plan de handoff / decommissioning al sponsor	15	NUEVA
Total		100	

Variante LLM / Gen AI

RESUMEN DE DIMENSIONES

Dim	Tema	Peso	Estado
DEP-A	Decisión go/no-go + cinco dimensiones de viabilidad (LLM)	25	MODIFICADA
DEP-B	Plataforma cloud LLM con TCO + lock-in + residencia + self-hostability	20	MODIFICADA
DEP-C	SLO + plan de monitoreo + drift detection (LLM)	20	NUEVA
DEP-D	Seguridad LLM: prompt injection + PII + jailbreaks + compliance	20	NUEVA
DEP-E	Plan de handoff LLM al sponsor	15	NUEVA
Total		100	

3. Dimensiones nuevas

Tres dimensiones nuevas, espejadas en ambas variantes (oficial y LLM). Cierran el ciclo entre “tenemos un modelo que funciona en eval” y “tenemos un sistema que vive en producción con responsable, monitoreo y plan de handoff”.

E6-C / DEP-C — SLO + plan de monitoreo en producción

QUÉ SE PIDE EN E6

Antes de decir “es viable”, definir **qué significa funcionar en producción**.

- **SLO objetivos numéricos:** latencia P50/P95, disponibilidad (99.5 % / 99.9 %), tasa de error aceptable, throughput máximo.
- **Plan de monitoreo:** qué se loggea, dónde se almacena, quién lo revisa, con qué cadencia.
- **Alertas:** thresholds que disparan acción (P95 >2s, error rate >1%, drift de input).
- **Métricas de calidad continua:** el modelo sigue cumpliendo el umbral E3-BL5 sobre datos de producción — no solo en eval set.
- Variante LLM (DEP-C): además, **drift detection** de queries + hallucination rate + drift de costo por consulta; evaluación continua vía LLM-as-judge si aplica.

E6-D / DEP-D — Seguridad, compliance y manejo de PII

QUÉ SE PIDE EN E6

Postura formal de seguridad — no “consideramos la seguridad” en una línea.

- **PII:** identificación de campos sensibles, política de retención, redaction, hashing, audit log de accesos.
- **Acceso y autenticación:** IAM roles, principio de menor privilegio, separación dev/prod, rotación de secretos.
- **Compliance regulatorio específico al sponsor:** Banxico (SOC, CNBV), Corona Colombia (Ley 1581), BMW (IP / GDPR), Taolab (HIPAA-like clínico).
- **Plan de respuesta a incidentes:** breach notification, rollback, data deletion request handling.
- Variante LLM (DEP-D): **prompt injection, jailbreaks** (red-teaming documentado), **fuga al proveedor del LLM** (¿opt-out de entrenamiento documentado?), **guardrails de salida**.

E6-E / DEP-E — Plan de handoff / decommissioning al sponsor

QUÉ SE PIDE EN E6

Cuando el proyecto termina, ¿qué se entrega para que el sistema siga vivo sin el equipo?

- **Artefactos:** código (repo + tag), modelo serializado, datos de entrenamiento, configuración cloud (Terraform o IaC).
- **Documentación operativa:** runbook (deploy, rollback, investigar incidentes), arquitectura, dependencias.
- **Transferencia de conocimiento:** sesión de handoff grabada con el equipo del sponsor.
- **Costos recurrentes:** ¿quién paga el cloud? ¿modelo de facturación? ¿punto de contacto?
- **Decommissioning plan:** si el sponsor decide no seguir, cómo se apaga limpio, qué datos se devuelven, qué se borran.

- Variante LLM (DEP-E): además, **prompts versionados** (repo + tag + criterio por versión) y **pipeline de retrieval** (chunker config, embedding model + versión, vector index, reranking).

4. Dimensiones modificadas

Dos dimensiones de la rúbrica oficial fueron refinadas. La variante LLM recibe los mismos refinamientos paralelos, con énfasis en TCO desglosado, capa de abstracción y self-hostability cuando data residency es restricción de EO.

Variante oficial — E6-A, E6-B

Dim	Tema	Cambio
E6-A	Decisión go/no-go condicional + recomendaciones accionables	Antes: “¿es viable? ¿margen para mejorar? ¿recomendaciones?”. Ahora: decisión explícita go / no-go / go-con-condiciones contra el modelo final de E5 + criterios stakeholder de EO; recomendaciones con dueño, plazo y métrica de éxito (no “explorar”, “considerar”); riesgos residuales documentados.
E6-B	Plataforma cloud con TCO + lock-in + residencia	Antes: “evaluar 4 nubes, justificar elección”. Ahora: defensa en tres ejes simultáneos — (a) TCO a 12 meses con números, (b) análisis de vendor lock-in y plan B, (c) residencia de datos atada a constraints de EO (Banxico, Corona Colombia, BMW IP).

Variante LLM / Gen AI — DEP-A, DEP-B

Dim	Tema	Cambio
DEP-A	Decisión go/no-go + cinco dimensiones de viabilidad (LLM)	Igual que E6-A + las cinco dimensiones tradicionales LLM (calidad, costo unitario, latencia, confiabilidad+seguridad, fallback). Recomendaciones con dueño, plazo y métrica de éxito.
DEP-B	Plataforma cloud LLM con TCO + lock-in + residencia + self-hostability	Igual que E6-B + comparativa TCO a 12 meses desglosando tokens input/output, vector index storage, egress, observabilidad; capa de abstracción (LangChain, LlamaIndex, LiteLLM) para portabilidad; self-hostability obligatoria si MAI lo declaró (data residency).

5. Síntesis

RESUMEN DE QUÉ CAMBIÓ

- **Dimensiones nuevas** (3 en cada variante): SLO + plan de monitoreo en producción (C), seguridad + compliance + PII (D), plan de handoff / decommissioning al sponsor (E).
- **Dimensiones modificadas** (2 en cada variante): A decisión explícita go/no-go contra E5-F + recomendaciones con dueño/plazo/métrica, B comparativa cloud con TCO 12m + vendor lock-in + residencia de datos.
- Variante LLM añade: drift detection + hallucination rate como métricas first-class (DEP-C), prompt injection + jailbreaks + fuga al proveedor (DEP-D), prompts versionados + pipeline de retrieval como artefactos del handoff (DEP-E).

IDEA CLAVE

“Es viable” sin **SLO definido + plan de monitoreo + responsable post-entrega** es una declaración aspiracional, no operacional. E6 cierra el ciclo que empezó en E0 (criterios stakeholder) — debe defenderse contra cada constraint declarado entonces.

Fuente: Entrega 6 Rúbrica, Canvas PI. Si tu proyecto cae en la categoría LLM/Gen AI/generativo no-textual, considera la columna derecha (DEP) en cada sección.