

Avance 3 • Modelo Baseline

Equipo 8 • Banxico — NLP información financiera (Banco de México (Banxico))

26 May 2026 · Asesor: **Dr. Horacio Martínez Alfaro** · hma@tec.mx

1. Evaluación por dimensión

Evaluación por dimensión, variante LLM (BL1–BL8).

RÚBRICA ADAPTADA LLM • BL1–BL8

Dim	Tema	Pts	Estado
BL1	Baselines trivial + simple (LLM)	10/15	Cubierto
BL2	Importancia de características (correlacional, no causal — L	10/10	Cubierto
BL3	Sub/sobreajuste, memorización y contaminación de datos	6/10	Cubierto
BL4	Métrica primaria declarada a priori (1 primaria + 2-3 secund	15/15	Cubierto
BL5	Desempeño mínimo = lift sobre baseline trivial + SLOs operat	7/10	Cubierto
BL6	Política de split y validación (LLM)	14/15	Cubierto
BL7	Reproducibilidad LLM (seed, temperature, prompt versioning)	8/10	Parcial
BL8	Análisis de errores LLM (retrieval, hallucination, validity)	12/15	Cubierto

2. Cálculo de la calificación

Componente	Valor
Subtotal L (per-dim)	82 / 100
Calificación final	82 / 100

3. Fortalezas que destacan

LO QUE ESTÁ BIEN HECHO

- Metodología de evaluación rigurosa y transparente: 5 baselines con métricas simétricas (NDCG@10, Recall@10, MAP@10, latencia), tabla de ablación con deltas cuantificados, y conclusión fundada en datos (embeddings semantic signal >advanced methods).
- Contaminación de datos y overfitting buscados proactivamente: no-context test ejecutado (GPT-4o-mini alucinó sin contexto) demuestra que el RAG aporta mayoría de certidumbre regulatoria. Reconocen limitaciones honestamente.
- Análisis de errores con ejemplos concretos y taxonomía clara: 3 categorías de fallo (retrieval / interpretación / formato) mapeadas a 5 casos reales con rangos de recuperación. Permite distinguir falla sistémica de método-particular.

- Ciclo de feedback pragmático alineado con operación: ROI de revisión humana cuantificado (5 min/output, multi-SME inviable semanal). Estrategia híbrida demuestra madurez en gestión de costos.

4. Áreas de oportunidad

BRECHAS OBSERVADAS

- Eval set insuficiente para generalización robusta: 30 queries <100 recomendado. Risk: conclusiones de generalización extraídas de muestra pequeña. Expandir a ≥100 queries (léxico, longitud, complejidad balanceadas) necesario para E4.
- Exact-match underestima retrieval semántico: frases parafraseadas o distribuidas en múltiples chunks fallan. Notebook lo reconoce pero no lo mide. Comparación exact_match vs llm_judge no tabulada.
- Reproducibilidad de modelo LLM incompleta: text-embedding-3-small sin versión exacta de API; gpt-4o-mini y gpt-4o sin dates; prompts en archivos Python sin versionado hash/git. Para E4, versioning obligatorio (DSPy, MLflow).
- Multi-chunk handling ausente: notebook menciona 'reserved for future'. Banxico requiere info de múltiples documentos regulatorios — crítico cerrar brecha en E4.

5. Recomendaciones para Avance 4

PLAN SUGERIDO PARA EL PRÓXIMO AVANCE

- **MA1** : implementar ≥6 configuraciones LLM con UNA self-hostable (Llama, Mistral, Gemma vía vLLM/TGI/Ollama). Razón: data residency Banxico México-only + independencia vendor lock-in.
- **MA2** : congelar eval set a ≥100 queries representativas (diferentes tipos doc, complejidad sintáctica, idioma). Pareto frontier (costo/consulta × NDCG@10) obligatorio. Contamination test POR CANDIDATO (GPT-4 vs Claude vs Llama tienen corpora distintos).
- **MA3** : versioned prompt registry para cada configuración (DSPy / MLflow / Promptfoo o .json timestamp+git hash). Tabla resumen: candidato | modelo | embedding | reranker | fine-tuning | hash prompt | costo/1k.
- **MA4** : top-2 tras ablation inicial, tuning profundo con held-out separado (evitar leakage del tuning). Chequeo contra E3-BL5 lift (+22pp ya logrado; target ≥25pp o reconocer límite inherente).
- **MA5 NUEVA** : bootstrap CI 1000 resamples por candidato. Paired-t por query sobre NDCG deltas, o McNemar si clasificación. CIs solapados → tied, elegir por costo/latencia. Reportar varianza entre runs con **temperature** >0 (Llama local non-determinism).
- **MA6 NUEVA** : error analysis para TODOS los candidatos: separar (a) retrieval falló chunk no top-K, (b) retrieval ok pero LLM alucinó, (c) generación ok formato incorrecto. Desagregación por tipo doc, complejidad, longitud query.
- **MA7 NUEVA** : costo + interpretabilidad + vendor lock-in. Latencia P50/P95 (ms), memoria pico, footprint artefacto. Interpretabilidad: embeddings opaca, BM25+metadata nativa. Vendor lock-in spectrum: self-hostable (Llama local) vs API (OpenAI, Anthropic).