

Avance 4 · Modelos Alternativos

Equipo 8 · Banxico — NLP información financiera (Banco de México (Banxico))

02 Jun 2026 · Asesor: **Dr. Horacio Martínez Alfaro** · hma@tec.mx

1. Evaluación por dimensión

Evaluación por dimensión, variante LLM (MA1-MA7).

RÚBRICA ADAPTADA LLM · MA1-MA7

Dim	Tema	Pts	Estado
MA1	6 configuraciones LLM con al menos una self-hostable	10/10	completo
MA2	Comparación multi-dimensional rigurosa (eval set + Pareto +	19/20	completo
MA3	Hiperparámetros LLM + versionado de prompts	10/10	completo
MA4	Top-2 + ajuste sin leakage + elección final con chequeo cont	14/15	completo
MA5	Significancia estadística LLM	15/15	completo
MA6	Análisis de errores LLM por candidato + desagregación	14/15	completo
MA7	Costo + interpretabilidad + vendor lock-in (LLM)	14/15	completo

2. Cálculo de la calificación

Componente	Valor
Subtotal L (per-dim)	96 / 100
Calificación final	96 / 100

3. Fortalezas que destacan

LO QUE ESTÁ BIEN HECHO

- Marco metodológico completo MA1-MA7 con matriz de alineación rúbrica→evidencia (cell 2) que facilita la auditoría — pocas entregas explicitan este mapeo.
- Reproducibilidad seria a nivel MLOps: prompts versionados con hash SHA-256 inyectado en telemetría (cells 8-9), eval set congelado de 109 queries, scripts core auditables (**evaluador_integral.py**, **prompts_registry.py**).
- Significancia estadística rigurosa y honesta: bootstrap CI 1000 + paired-t + McNemar + bootstrap pareado (cells 39-41); reconoce empate estadístico y decide por criterios operativos en lugar de inflar resultados.
- Análisis crítico del leniency bias nube vs local (cells 48-50) con evidencia cuantitativa (43 vs 0 errores B) — valida por qué Llama 8B local no sirve como juez final y justifica model cascading.

4. Áreas de oportunidad

BRECHAS OBSERVADAS

- Taxonomía A/B/C ejecutada para pipeline híbrido completo pero no por candidato individual (declarado honestamente en cell 45) — limita la lectura inter-candidato de errores de generación.
- P95 y memoria reportados como proxy (cells 51-53), no medición real — falta integrar `telemetria_llm.jsonl` con latencias por consulta y memoria pico para convertir tabla cualitativa en telemetría continua.
- MA4 verifica held-out conceptualmente pero no ejecuta tuning profundo nuevo (declarado en cell 33: 'no hicimos fine-tuning ni optimización automática de prompts'); el ajuste se limita a incorporación gradual de componentes.
- Chequeo explícito vs umbral E3-BL5 (regla crítica MA4) se infiere de la conclusión pero no se enuncia con número concreto: 'final vs BL5 = Δ con CI' falta como tabla dedicada.

5. Recomendaciones para Avance 5

PLAN SUGERIDO PARA EL PRÓXIMO AVANCE

- MA6 E5: extender `evaluar_desagregacion_errores` para iterar sobre los 6 candidatos (no solo el pipeline híbrido); basta clasificar 10-15 fallos por candidato en (A/B/C) usando los CSV ya generados. ~1-2 h.
- MA7 E5: medir P95 real desde `telemetria_llm.jsonl` (parsear el JSONL, agrupar por candidato, percentile 95 con numpy); reemplazar tabla proxy por valores observados. ~1 h.
- MA4 E5: añadir tabla 1-fila comparando NDCG@10 del candidato final (`2_Baseline_Semántico` 0.8457) contra umbral E3-BL5 declarado, con CI bootstrap del delta. Si pasa por margen significativo, queda documentado; si no, declarar pivote. ~30 min.
- Ensamble E5: con el Top-2 ya identificado, construir un router/cascade que envíe consultas de crédito al `6_SOTA_Completo` y el resto a `2_Baseline_Semántico` (lo recomienda la propia conclusión cells 35/38); reportar Δ NDCG vs ganador único + costo extra. ~3-4 h.
- Análisis de errores generativos E5 sobre 20-30 muestras del candidato final con etiquetas (útil/parcial/incorrecta/alucinación/refusal) — cierra el lado generación que la taxonomía A/B/C ya marcó como cuello de botella secundario. ~1-2 h.