

Rúbrica adaptada para proyectos con componente LLM / PLN

Análisis Exploratorio de Datos (EDA) e Ingeniería de Características (FE) en proyectos basados en Modelos de Lenguaje a Gran Escala

Asesor: **Dr. Horacio Martínez Alfaro** · Documento de referencia para los equipos cuyos proyectos involucran LLMs (RAG, ajuste fino, ingeniería de indicaciones, agentes de IA).

En un proyecto de ML tradicional, el análisis exploratorio de datos (EDA) se centra en características numéricas y categóricas, distribuciones y relaciones tabulares. En un proyecto de LLM (RAG, fine-tuning, prompt engineering), los datos son **principalmente texto no estructurado**. Por lo tanto, el EDA debe centrarse en las propiedades **textuales, semánticas y estructurales**.

Esta rúbrica adapta las 10 preguntas del EDA tradicional (Q1–Q10) a 6 categorías para contexto LLM (L1–L6), más una sección de Ingeniería de Características adaptada (FE1–FE5).

Parte 1 · EDA adaptado para LLM (L1–L6)

L1 Valores faltantes y controles de calidad ↔ Q1

- Tradicional:** ¿Hay valores faltantes en el conjunto de datos? ¿Se pueden identificar patrones de ausencia?
- Adaptación LLM:** ¿Hay cadenas vacías, fragmentos de documentos faltantes o etiquetas de metadatos faltantes? En datos de texto, "faltante" también puede significar **texto corrupto**, errores de codificación sin resolver (como `Ã©`) o contexto faltante en un conjunto de datos conversacionales.

L2 Estadísticas descriptivas y distribuciones ↔ Q2 + Q5

- Tradicional:** ¿Cuáles son las estadísticas descriptivas? ¿Existen distribuciones sesgadas? ¿Se necesitan transformaciones no lineales?
- Adaptación LLM:** Analizar el **recuento de tokens y palabras**. ¿Cuál es la distribución de la longitud del texto en sus documentos o indicaciones?

Por qué es importante: Los LLMs tienen límites estrictos de ventana de contexto. Si su distribución está muy sesgada hacia documentos muy largos, deberá aplicar un paso de preprocesamiento como la segmentación (chunking) para dividir el texto.

L3 Valores atípicos y anomalías ↔ Q3

Tradicional: ¿Hay valores atípicos en el conjunto de datos?

Adaptación Los valores atípicos en texto se ven diferentes. Hay que buscar:

LLM:

- Textos inusualmente cortos (p. ej. "ok", "sí") que no proporcionan contexto.
- Textos inusualmente largos que podrían ser volcados de datos.
- Textos en idiomas inesperados (mediante detección de idioma).
- Textos sin sentido, etiquetas HTML pesadas o caracteres especiales excesivos (que requieren limpieza durante el preprocesamiento).

L4 Cardinalidad y desequilibrio de clases ↔ Q4 + Q10

Tradicional: ¿Cuál es la cardinalidad de las variables categóricas? ¿Existe desequilibrio de clases en la variable objetivo?

Adaptación Aún sin una "variable objetivo" tradicional, es necesario comprender la diversidad de los datos:

- **Distribución temática** — si se agrupan textos usando embeddings, ¿la mayoría de los documentos tratan sobre un solo tema?
- **Diversidad de instrucciones/intenciones** — para ajuste fino, ¿hay desequilibrio en tipos de instrucciones (p. ej. 90 % "resumir" y solo 10 % "lluvia de ideas")?

L5 Correlación y análisis bivariado · Similitud semántica ↔ Q7 + Q8

Tradicional: ¿Existe correlación entre variables dependientes e independientes? ¿Cómo se distribuyen los datos entre diferentes categorías?

Adaptación "Correlación" se traduce en **similitud semántica**:

LLM:

- **Para proyectos RAG** — analizar la similitud semántica (usando embeddings vectoriales) entre las consultas de usuario esperadas y los fragmentos de documentos reales. Si hay poca superposición semántica, el sistema de recuperación fallará.
- **Visualización de embeddings** — usar técnicas de reducción de dimensionalidad (UMAP o t-SNE) para visualizar cómo se agrupan los datos.

L6 Tendencias temporales ↔ Q6

Tradicional: ¿Se identifican tendencias temporales?

Adaptación LLM: Si los datos de texto abarcan un período de tiempo (artículos de noticias, reseñas de clientes), ¿cambia el vocabulario o el tema principal con el tiempo? Esto es importante para saber si el LLM podría sufrir problemas de **interrupción del conocimiento** o **deriva conceptual**.

Operaciones de preprocesamiento sugeridas para LLM

Para proyectos LLM, reemplazar la imputación y el escalado tradicionales con:

- **Normalización de texto** — conversión a minúsculas, eliminación de información personal identificable (PII), eliminación de formato Markdown/HTML.
- **Segmentación (chunking)** — dividir documentos largos en segmentos más pequeños y superpuestos que se ajusten a la ventana de contexto del LLM.
- **Generación de embeddings** — convertir el texto limpio en representaciones vectoriales para análisis y recuperación.

Parte 2 · Feature Engineering adaptado para LLM (FE1–FE5)

En proyectos LLM, el "Feature Engineering" se aleja de transformaciones matemáticas de columnas y se centra en **optimizar representaciones de texto, estructurar contexto y preparar vectores semánticos**.

FE1 Generación de nuevas características → Extracción de metadatos y enriquecimiento de contexto

Tradicional: Crear una nueva columna "BMI" a partir de "Altura" y "Peso".

LLM: En sistemas RAG, los fragmentos de texto crudos no son suficientes. Usar un LLM para **extraer metadatos** de los documentos antes de indexarlos: tema principal, fecha, autor, etc., y adjuntarlos al documento.

Justificación: permite búsqueda híbrida (filtrar por metadatos antes de la búsqueda vectorial), mejora la precisión de recuperación y reduce alucinaciones.

FE2 Discretización / binning → Estrategias de chunking

Tradicional: Agrupar edades continuas en bins discretos (18-25, 26-35).

LLM: Los LLMs tienen ventanas de contexto finitas. Hay que "discretizar" el texto en chunks: tamaño fijo de tokens, por oración, o semántico (por párrafos o secciones lógicas).

Justificación: hay que justificar tamaño del chunk y solapamiento. Demasiado pequeño → el LLM pierde contexto. Demasiado grande → se diluye el significado semántico o se excede el límite de tokens.

FE3 Codificación → Embeddings vectoriales

Tradicional: Convertir "Rojo, Verde, Azul" en 1s y 0s (one-hot).

LLM: Codificar chunks de texto en representaciones vectoriales densas usando un modelo de embeddings (text-embedding-ada-002 u open source).

Justificación: elegir el modelo de embeddings según dimensionalidad, límite de contexto y desempeño en el idioma/dominio específico (p. ej. un modelo médico si el texto es clínico).

FE4 Escalamiento → Normalización vectorial y estandarización de texto

Tradicional: Escalar ingresos para que estén entre 0 y 1.

LLM: Dos vertientes:

- **Normalización vectorial** — muchas bases de datos vectoriales requieren L2-normalización para que la similitud coseno sea rápida y numéricamente estable.
- **Estandarización de texto** — convertir HTML/tablas/PDFs en Markdown estandarizado antes de generar embeddings.

Justificación: estandarizar el formato textual asegura que el LLM lea datos tabulares o estructurados de forma consistente, mejorando su razonamiento.

FE5 Transformaciones → Transformaciones de consulta (HyDE / Query Expansion)

Tradicional: Aplicar logaritmo para corregir distribuciones sesgadas.

LLM: A veces el prompt del usuario es demasiado corto o mal formulado para recuperar buenos datos. Se aplican "transformaciones" a la consulta. Técnica común: **HyDE** (Hypothetical Document Embeddings) — un LLM genera una respuesta hipotética a la consulta, y se usa ese texto generado para buscar en la base.

Justificación: transformar la consulta cierra la brecha semántica entre una pregunta corta de usuario y un chunk de documento largo y detallado, mejorando el recall de recuperación.

Mapecto Q ↔ L (referencia rápida)

Pregunta oficial (Q1–Q10)	Categoría LLM (L1–L6)
Q1 — Valores faltantes	L1 — Faltantes / calidad textual
Q2 — Estadísticas resumidas	L2 — Distribución de tokens y longitudes
Q3 — Valores atípicos	L3 — Outliers textuales
Q4 — Cardinalidad de categóricas	L4 — Cardinalidad / diversidad temática
Q5 — Distribuciones sesgadas / transformaciones	L2 (junto con Q2)
Q6 — Tendencias temporales	L6 — Deriva de vocabulario / tema
Q7 — Correlación dep./indep.	L5 — Similitud semántica
Q8 — Distribución por categorías (bivariado)	L5 (junto con Q7)
Q9 — Normalización de imágenes	(no aplica a LLM puro)
Q10 — Desequilibrio de clases	L4 (junto con Q4)

Documento de referencia · Adaptación de la rúbrica de EDA y Feature Engineering del Proyecto Integrador MNA para equipos cuyos proyectos involucran LLMs/PLN. Para dudas, contactar a su asesor.

Asesor: Dr. Horacio Martínez Alfaro · hma@tec.mx